

Learning Humanoid Robot Motions through Deep Neural Networks

II Brazilian Humanoid Robot Workshop

Luckeciano C. Melo

Prof. Dr. Marcos R. O. A.
Máximo

Prof. Dr. Adilson Marques da
Cunha


Background

Descrição do Domínio




Introdução


Chute - Keyframe



T1



T2




T3

Introdução


Objetivo

Encontrar políticas ótimas para o movimento de chute do robô humanoide por meio de Supervised Imitation Learning



Deep Learning

Redes Neurais





$$J(\boldsymbol{\theta}) = -\mathbb{E}_{\mathbf{x}, \mathbf{y} \sim \hat{p}_{data}} \log p_{model}(\mathbf{y}|\mathbf{x})$$

$$\nabla_{\mathbf{x}} z = \sum_j (\nabla_{\mathbf{x}} Y_j) \frac{\partial z}{\partial Y_j}$$

Introdução

Aprendizado → Problema de Otimização




Metodologia

Aprendizado Supervisionado - Overview



Metodologia

Aprendizado Supervisionado - Dataset



Metodologia

Aprendizado Supervisionado - Arquitetura




TABLE 4.1 – The Network Summary

Layer	Neurons	Activation	Parameters
Dense	75	LeakyReLU	130
Dense	50	LeakyReLU	3800
Dense	23	Linear	1173

Total Parameters	5123
-------------------------	-------------

Metodologia - Hiperparâmetros



- 50k épocas
- Learning Rate: 0.001 (30k épocas), 0.0008 (5k épocas), 0.0006 (5k épocas), 0.0004 (5k épocas), 0.0002 (5k épocas)
- Otimizador Adam
- Dataset: Reprodução de um único chute (128 amostras)

Metodologia


Infraestrutura



Computação em nuvem gratuita está disponível para os membros da Intel® AI Academy. Use o Intel® AI DevCloud equipado com processadores escalonáveis Intel® Xeon® para treinamento de aprendizado de máquina e aprendizagem profunda e necessidades de computação de inferência.

Resultados

Resultados - Treino Supervisionado




Resultados

Resultados - Chute Aprendido

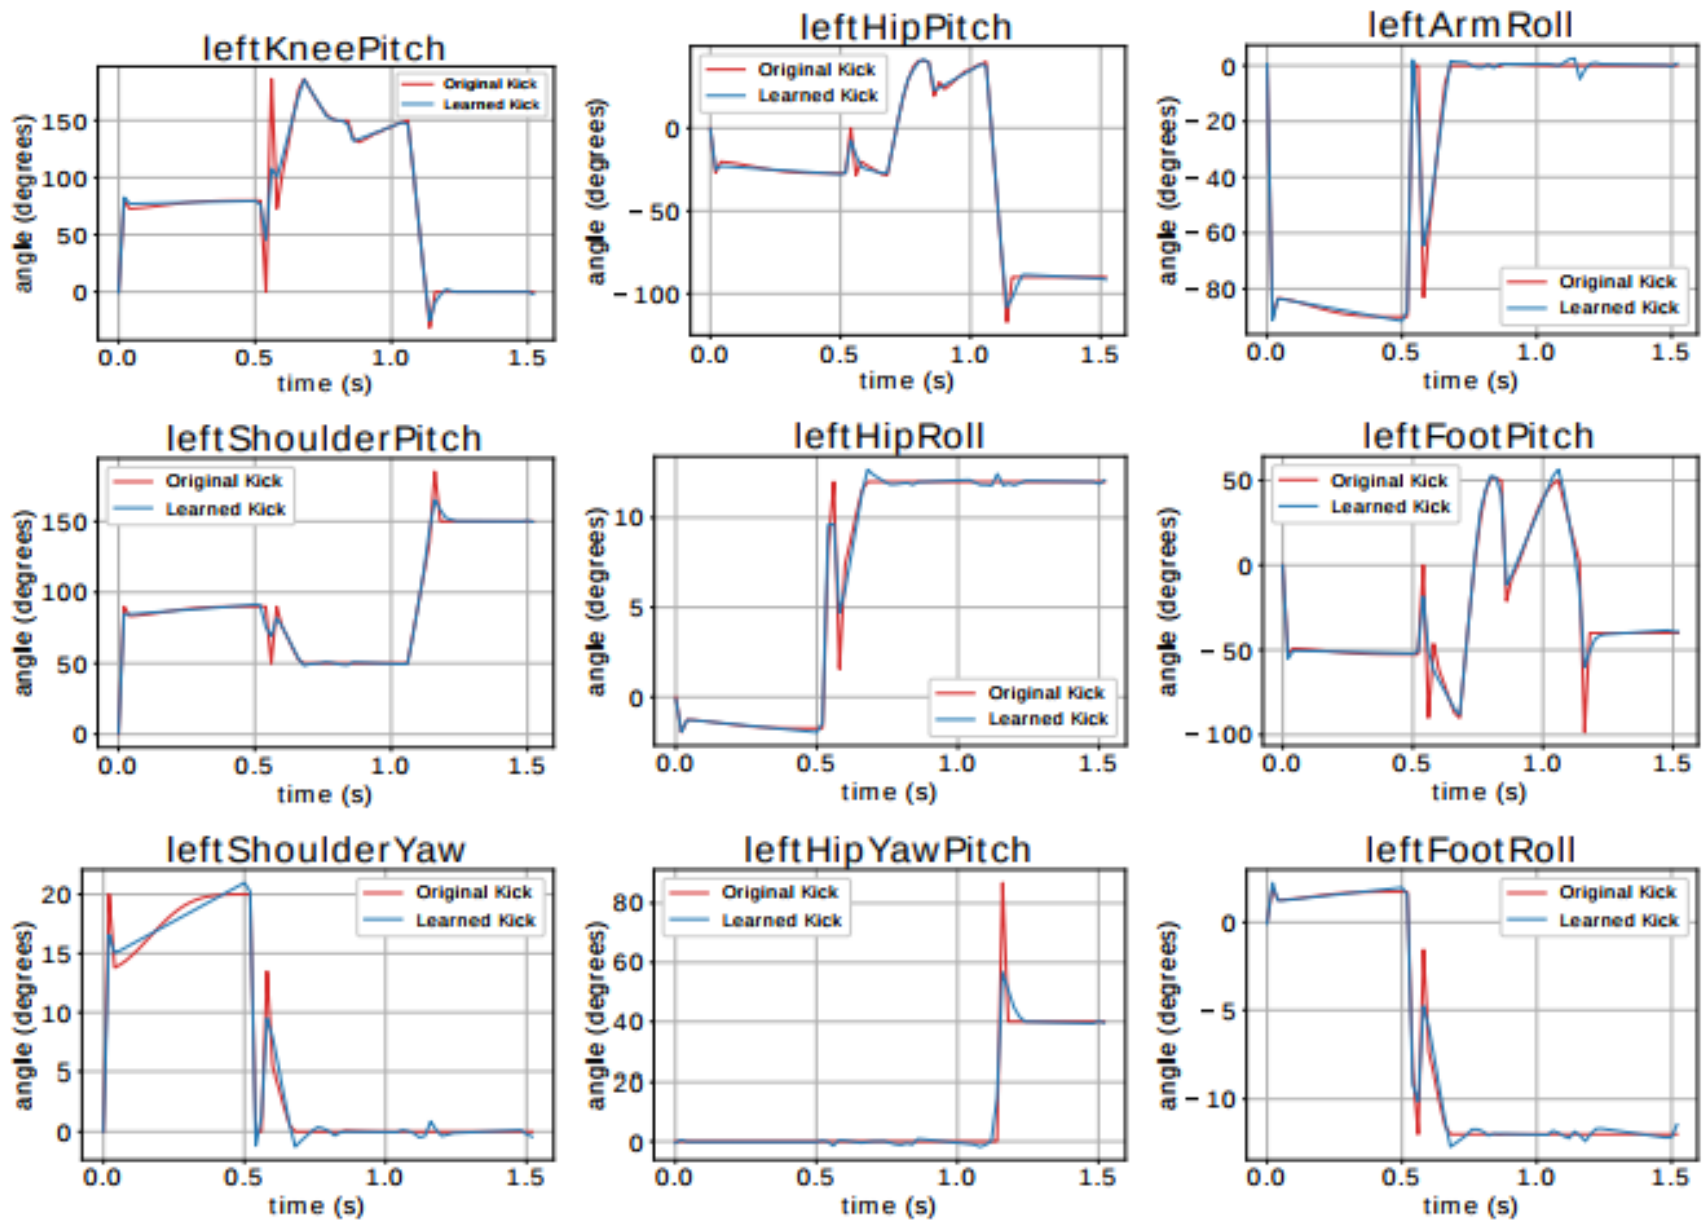


Keyframe



Neural Network

Resultados




Resultados

TABLE 5.1 – The Kick Comparison


Kick Type	Statistics		
	<i>Accuracy (%)</i>	<i>Distance (m)</i>	
		<i>Mean</i>	<i>Std</i>
Original Kick	64.5	8.92	3.82
Neural Kick	52.6	7.16	4.06

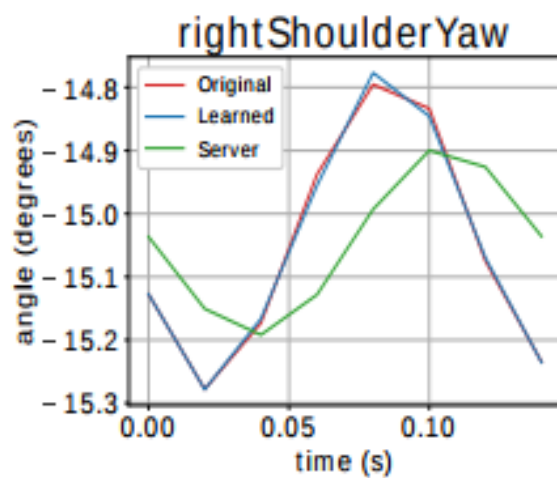
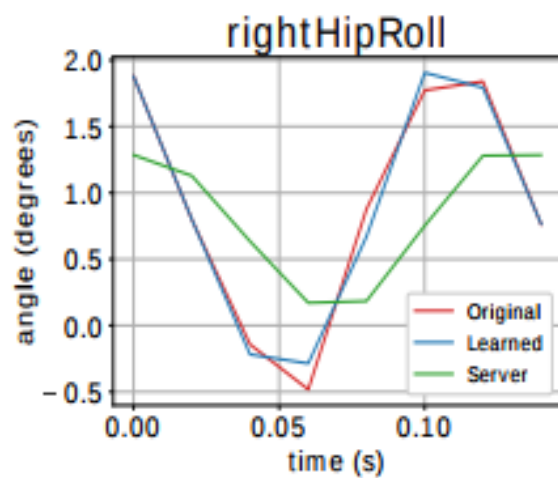
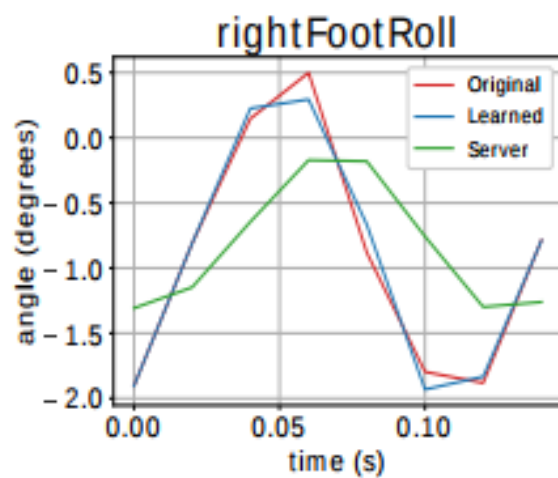
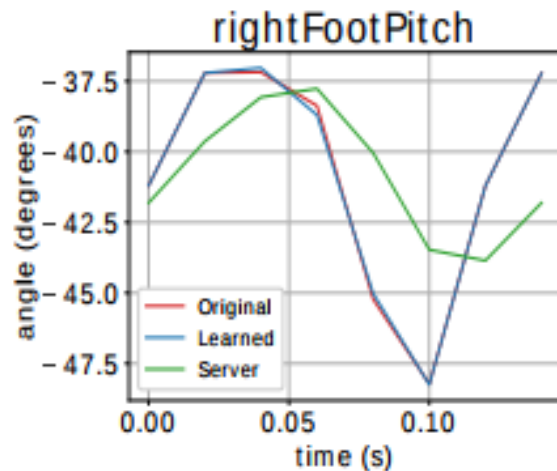
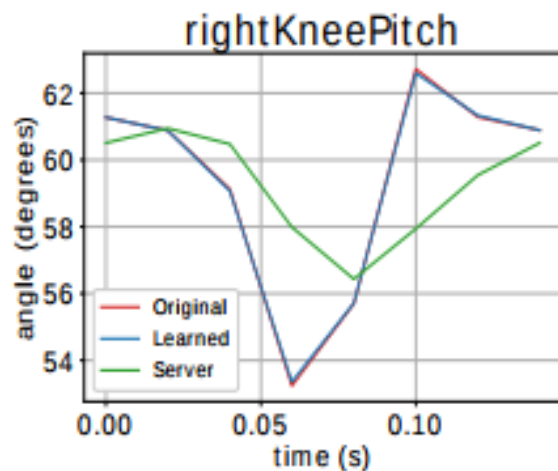
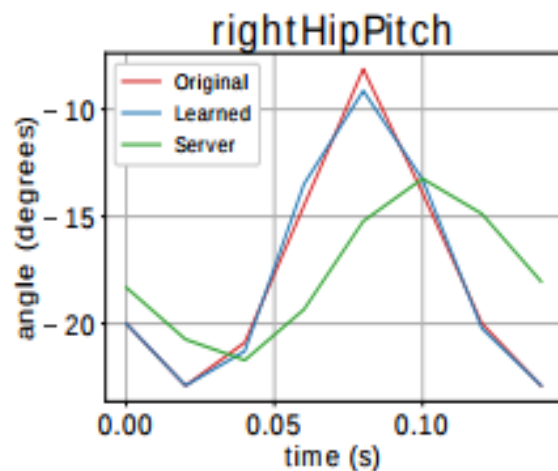
- **Bônus: É possível copiar movimentos de adversários!**

Resultados



Aprendizado de Caminhada





Aprendizado de Caminhada

Walk Type	Statistics			
	Velocity (m/s)		Y Error (m)	
	<i>Mean</i>	<i>Std</i>	<i>Mean</i>	<i>Std</i>
Original Walk	0.87	0.01	-	-
Learned Walk	0.23	0.01	0.96	2.63



Conclusões



- É possível transferir o conhecimento de um movimento de keyframe para uma rede neural com um pequeno erro residual;
- A framework de aprendizado apresentado é capaz de aprender diversos tipos de movimentos, como caminhada e chute, sem mudança na arquitetura ou hiperparâmetros;
- Também é capaz de copiar movimentos de outros times, sem nenhum conhecimento prévio a respeito da implementação.

Agradecimentos



- **General Sponsors: ITAEx, Altium, Mathworks, Metinjo, Micropress, Poliedro, Polimold, Pouplex, FHC, Rapid e Solidworks;**
- **Intel → Recursos Computacionais e Otimizações do uso do hardware para AI;**
- **Patrick MacAlpine (UT Austin Villa) e**
- **ITA e todo o time da ITAndroids, especialmente para o da categoria RoboCup Soccer 3D simulation.**