

Relatório do Laboratório 8:

Imitation Learning com Keras

Isabelle Ferreira de Oliveira
CT-213 - Engenharia da Computação 2020
Instituto Tecnológico de Aeronáutica (ITA)
São José dos Campos, Brasil
isabelle.ferreira3000@gmail.com

Resumo—Esse relatório documenta a cópia de um movimento de caminhada de um robô humanoide usando a técnica chamada *imitation learning*. Para isso, foi utilizado o *framework* de *Deep Learning* Keras, que facilita o uso do *framework* Tensorflow.

Index Terms—*Imitation learning, deep learning, Keras, Tensorflow*

I. INTRODUÇÃO

Deep learning é um tipo de aprendizado de máquina que treina para aprender através do reconhecimento de padrões em várias camadas de processamento. Entre as tarefas possíveis realizáveis estão o reconhecimento de fala, identificação de imagem e previsões, entre outras tarefas realizadas por seres humanos.

Esse tipo de estratégia possibilita, também, aprender por imitação. Assim, o comportamento desejado (uma política de controle, por exemplo) é copiado usando aprendizado supervisionado.

O *framework* Keras facilita o uso do *framework* Tensorflow para problemas de *Deep learning*, transformando a implementação, treino e resultado da rede neural em chamadas de API. O funcionamento dessas chamadas pode ser visto a seguir. Em seguida, será apresentado como isso foi aplicado no contexto do laboratório.

```
from keras import models

# Creates the neural network model in Keras
model = models.Sequential()

Sequential() cria uma pilha linear de camadas.
```

```
from keras import layers, activations,
regularizers

# Adds the first layer
model.add(layers.Dense(num_neurons,
    activation=activations.some_function,
    input_shape=(input_size,),
    kernel_regularizer=regularizers.l2(lambda)))

# Adds another layer (not first)
model.add(layers.Dense(num_neurons,
    activation=activations.some_function,
    kernel_regularizer=regularizers.l2(lambda)))
```

Para a criação de uma camada na rede neural através do Keras, utiliza-se a função `model.add(layers.Dense())`, sendo o primeiro argumento referente ao número de neurônios nessa camada; "activation" configura a função de ativação; "input_shape" representa o tamanho da entrada; e "kernel_regularizer" configura a regularização para essa camada.

```
from keras import losses, optimizers, metrics

# Configures the model for training
model.compile(optimizer=optimizers.Adam(),
    loss=losses.binary_crossentropy,
    metrics=[metrics.binary_accuracy])

# Trains the model for a given number of epochs
history = model.fit(inputs,
    expected_outputs,
    batch_size=size_of_batch,
    epochs=num_epochs)
```

Por fim, configura-se o modelo para o treino, escolhendo o otimizador, a função de custo e as métricas; e se treina o modelo para um determinado conjunto de entrada, tendo as saídas esperadas, o tamanho do batch e quantas épocas serão efetuadas.

II. IMPLEMENTAÇÃO

Para a implementação da rede neural conforme os parâmetros requisitados pelo roteiro do laboratório [1] e apresentada na tabela da Figura 1, era necessário utilizar do código de adição de camadas a uma rede, além de configuração e treino do modelo, apresentado na Introdução.

Tendo em vista que em *keras.activations* não há função de ativação Leaky ReLU, utilizou-se a recomendação sugerida pelo roteiro [1] para usar Leaky ReLU no Keras, ou seja, foi adicionado uma camada do tipo LeakyRelu após ter definido uma camada (usando função de ativação linear).

Além disso, para configurar o modelo, setou-se o parâmetro *loss* da função *compile()* para *losses.mean_squared_error*, uma vez que foi utilizado erro quadrático.

Por fim, para treinar, o tamanho do *batch* foi o tamanho total de entradas, para que seja usado todo o *dataset* em cada iteração do treinamento.




Figura 1. Arquitetura da rede neural usada para a imagem foi apresentada no roteiro [1].

III. RESULTADOS E CON

A. Estudo de implementação de Rede

O código do arquivo *test_keras.py* foi estudado para se entender a utilização do *framework* Keras na implementação de redes neurais. O que foi aprendido resultou no texto escrito na Introdução.

B. Análise do efeito de Regularização

Esse arquivo *test_keras.py* continha a dizado das funções "soma maior que zero" e "xor".

Após a execução desse arquivo, o apresentados nas Figuras de 2 a 11, os *dataset* utilizados para as funções "xor", respectivamente.

Analisando os resultados, é possível situações (com e sem regularização, e a rede obteve uma classificação satisfatória com regularização, entretanto, apresentou-se conforme se pode observar pelas comp 6 para "soma maior que zero" e 9 e 11

A questão da convergência da função pode ser comparada. Para os casos de convergência se deu bem antes em número de épocas. Isso pode ser observado nas Figuras 3 e 5, para "soma maior que zero" e nas Figuras 8 e 10 para "xor".

C. Imitation Learning

Após a implementação da rede neural com Keras conforme o explicado na seção Implementação, os resultados obtidos estão apresentados nas Figuras de 12 a 16. A comparação entre os gráficos de azul (curva original) e laranja (função aprendida por rede neural) dessas figuras demonstra que a implementação aconteceu de maneira satisfatória, uma vez que as funções ficaram bastante semelhantes.

Tendo em vista o que foi apresentado, pode-se notar, por fim, que algoritmos de *Deep learning* e o *framework* Keras realmente se demonstraram eficazes em realizar aprendizado por imitação.




Figura 2. *Dataset* utilizado para o aprendizado da função *soma > 0*




Figura 3. Convergência da função de custo para a função *soma > 0*, sem regularização.

REFERÊNCIAS

- [1] M. Maximo, "Roteiro: Laboratório 8 - Imitation Learning com Keras". Instituto Tecnológico de Aeronáutica, Departamento de Computação. CT-213, 2019.




Figura 4. Resultado da classificação por rede neural para a função $soma > 0$, sem regularização.

Example: 4449. Expected Label: 6. Predicted Label: 6.




Figura 6. Resultado da classificação por rede neural para a função $soma > 0$, com regularização.

Example: 1798. Expected Label: 3. Predicted Label: 3.




Figura 7. Dataset utilizado para o aprendizado da função xor .

Example: 3758. Expected Label: 4. Predicted Label: 4.




Figura 5. Convergência da função de custo para a função $soma > 0$, com regularização.

Example: 2082. Expected Label: 2. Predicted Label: 2.




Figura 8. Convergência da função de custo para a função xor , sem regularização.

Example: 2439. Expected Label: 2. Predicted Label: 2.




Figura 9. Resultado da classificação por rede neural para a função *xor*, sem regularização.

Example: 18. Expected Label: 3. Predicted Label: 8.




Figura 12. Resultado da classificação por rede neural para a função *soma > 0*.

Example: 8. Expected Label: 5. Predicted Label: 6.




Figura 10. Convergência da função de custo para a função *xor*, com regularização.

Example: 247. Expected Label: 4. Predicted Label: 2.




Figura 13. Resultado do *Imitation learning* para Right Ankle Roll.

Example: 92. Expected Label: 9. Predicted Label: 4.




Figura 11. Resultado da classificação por rede neural para a função *xor*, com regularização.

Example: 321. Expected Label: 2. Predicted Label: 7.




Figura 14. Resultado do *Imitation learning* para Right Hip Pitch.