

Relatório do Laboratório 11: Programação Dinâmica

Isabelle Ferreira de Oliveira
CT-213 - Engenharia da Computação 2020
Instituto Tecnológico de Aeronáutica (ITA)
São José dos Campos, Brasil
isabelle.ferreira3000@gmail.com

Resumo—Esse relatório documenta a implementação de algoritmos de programação dinâmica no contexto de solução de um Processo Decisório de Markov (Markov Decision Process - MDP). Os algoritmos implementados serão avaliação de política (policy evaluation), iteração de política (policy iteration) e iteração de valor (value iteration), com o objetivo de avaliar políticas e determinar políticas ótimas para um grid world.

Index Terms—MDP, policy evaluation, policy iteration, value iteration

I. IMPLEMENTAÇÃO

A. Implementação de Avaliação de Política

Essa parte tratava-se da implementação da função *policy_evaluation()*, presente no arquivo *dynamic_programming.py*, fornecido pelo código base do professor. De maneira simples, essa função consiste na equação:
$$v_{k+1}(s) = \sum_{a \in A} \pi(a|s) r(s, a) + \gamma \sum_{a \in A} \sum_{s' \in S} \pi(a|s) p(s'|s, a) v_k(s'),$$
 apresentada de forma bem semelhante no roteiro do laboratório [1].

Para implementá-la, os estados s (como também s') se tornaram tuplas (i, j) , que foram iteradas por todo o grid world. Foram feitos loops também para iterar pelas ações a , e os resultados da equação acima foram somados ao valor associado ao estado em que se estava nessa iteração.

- 1) $\pi(a|s)$ era encontrado em *policy*;
- 2) $r(s, a)$ estava em *grid_world.reward()*;
- 3) $p(s'|s, a)$ estava em *grid_world.transition_probability()*;
- 4) $v_k(s')$ era a *policy* para um outro estado s' .

O valor de $\pi(a|s)$ era encontrado no parâmetro *policy[current_state][action]*, assim como $r(s, a)$ estava em *grid_world.reward(current_state, action)*, $p(s'|s, a)$ estava em *grid_world.transition_probability(current_state, action, next_state)*, e $v_k(s')$ era a *policy* para um outro estado s' .

B. Implementação de Iteração de Valor

C. Implementação de Iteração de Política

D. Comparação entre Grid Worlds diferentes

1) *Função detect()*: Essa função tratava-se principalmente de três ações, a se saber: primeiro, era pré-processada a imagem de entrada (através da função *preprocess_image()*); segundo, essa entrada pré-processada servia de entrada

para rede, levando-a a um output; por fim, esse output era processado pelo algoritmo YOLO (através da função *process_yolo_output()*), retornando, então, informações de onde estariam a bola e os dois postes da trave. A predição da rede do segundo passo foi implementado com a função *predict()*, do Keras.

2) *Função preprocess_image()*: Essa função foi implementada com forte inspiração nas últimas três dicas da seção Dicas fornecidas pelo roteiro [1], com o detalhe adicional de dividir os elementos do vetor da imagem por 255, a fim de transformar os valores RGB em valores de 0 a 1.

3) *Função process_yolo_output()*: Para processar o output através do algoritmo YOLO, percorreu-se a matriz output, guardando quais índices detinham a maior probabilidade de haver bola, a maior e a segunda maior probabilidade de haver postes de trave. Tendo posse desses índices, o restante das informações eram processados de acordo com as equações apresentadas na página 3 do roteiro do laboratório [1]. Por fim, era retornada essas informações processadas da bola e das duas traves.

II. RESULTADOS E CONCLUSÕES

A. Implementação da rede em Keras

Ao se executar o script *make_detector_network.py*, o resultado foi igual ao apresentado na Tabela 1 do roteiro [1], comprovando a correta implementação da rede. Esse resultado pode ser visto nas Figuras 1 e 2.

B. Algoritmo YOLO

Uma amostra das imagens geradas pelo algoritmo de detecção de objetos YOLO foram reproduzidos nas Figuras de 3 a 7. Por essas imagens consegue-se observar o correto funcionamento do algoritmo, indicando que a implementação foi feita corretamente. Assim como esperado, então, conseguiu-se detectar a bola e os postes das traves nas imagens fornecidas pelo professor.

Tendo em vista o que foi apresentado, pode-se notar, por fim, que a rede e o algoritmo YOLO realmente se demonstrou eficaz em realizar essa detecção de objetos em imagens.

REFERÊNCIAS

- [1] M. Maximo, "Roteiro: Laboratório 11 - Programação Dinâmica". Instituto Tecnológico de Aeronáutica, Departamento de Computação. CT-213, 2019.

Layer (type)	Output Shape	Param #	Connected to
input_1 (InputLayer)	(None, 120, 160, 3)	0	
conv_1 (Conv2D)	(None, 120, 160, 8)	216	input_1[0][0]
norm_1 (BatchNormalization)	(None, 120, 160, 8)	32	conv_1[0][0]
leaky_relu_1 (LeakyReLU)	(None, 120, 160, 8)	0	norm_1[0][0]
conv_2 (Conv2D)	(None, 120, 160, 8)	576	leaky_relu_1[0][0]
norm_2 (BatchNormalization)	(None, 120, 160, 8)	32	conv_2[0][0]
leaky_relu_2 (LeakyReLU)	(None, 120, 160, 8)	0	norm_2[0][0]
conv_3 (Conv2D)	(None, 120, 160, 16)	1152	leaky_relu_2[0][0]
norm_3 (BatchNormalization)	(None, 120, 160, 16)	64	conv_3[0][0]
leaky_relu_3 (LeakyReLU)	(None, 120, 160, 16)	0	norm_3[0][0]
max_pool_3 (MaxPooling2D)	(None, 60, 80, 16)	0	leaky_relu_3[0][0]
conv_4 (Conv2D)	(None, 60, 80, 32)	4608	max_pool_3[0][0]
norm_4 (BatchNormalization)	(None, 60, 80, 32)	128	conv_4[0][0]
leaky_relu_4 (LeakyReLU)	(None, 60, 80, 32)	0	norm_4[0][0]
max_pool_4 (MaxPooling2D)	(None, 30, 40, 32)	0	leaky_relu_4[0][0]
conv_5 (Conv2D)	(None, 30, 40, 64)	18432	max_pool_4[0][0]
norm_5 (BatchNormalization)	(None, 30, 40, 64)	256	conv_5[0][0]
leaky_relu_5 (LeakyReLU)	(None, 30, 40, 64)	0	norm_5[0][0]
max_pool_5 (MaxPooling2D)	(None, 15, 20, 64)	0	leaky_relu_5[0][0]

Figura 1. Primeira parte do summary da rede implementada em Keras.

max_pool_5 (MaxPooling2D)	(None, 15, 20, 64)	0	leaky_relu_5[0][0]
conv_6 (Conv2D)	(None, 15, 20, 64)	36864	max_pool_5[0][0]
norm_6 (BatchNormalization)	(None, 15, 20, 64)	256	conv_6[0][0]
leaky_relu_6 (LeakyReLU)	(None, 15, 20, 64)	0	norm_6[0][0]
max_pool_6 (MaxPooling2D)	(None, 15, 20, 64)	0	leaky_relu_6[0][0]
conv_7 (Conv2D)	(None, 15, 20, 128)	73728	max_pool_6[0][0]
norm_7 (BatchNormalization)	(None, 15, 20, 128)	512	conv_7[0][0]
leaky_relu_7 (LeakyReLU)	(None, 15, 20, 128)	0	norm_7[0][0]
conv_skip (Conv2D)	(None, 15, 20, 128)	8192	max_pool_6[0][0]
conv_8 (Conv2D)	(None, 15, 20, 256)	294912	leaky_relu_7[0][0]
norm_skip (BatchNormalization)	(None, 15, 20, 128)	512	conv_skip[0][0]
norm_8 (BatchNormalization)	(None, 15, 20, 256)	1024	conv_8[0][0]
leaky_relu_skip (LeakyReLU)	(None, 15, 20, 128)	0	norm_skip[0][0]
leaky_relu_8 (LeakyReLU)	(None, 15, 20, 256)	0	norm_8[0][0]
concat (Concatenate)	(None, 15, 20, 384)	0	leaky_relu_skip[0][0] leaky_relu_8[0][0]
conv_9 (Conv2D)	(None, 15, 20, 10)	3850	concat[0][0]
Total params: 445,346			
Trainable params: 443,938			
Non-trainable params: 1,408			

Figura 2. Segunda parte do summary da rede implementada em Keras, com a última linha da Figura 1 como primeira linha dessa figura.




Figura 3. Detecção de uma bola através do algoritmo de YOLO.




Figura 4. Detecção de uma bola e de um dos postes da trave através do algoritmo de YOLO.

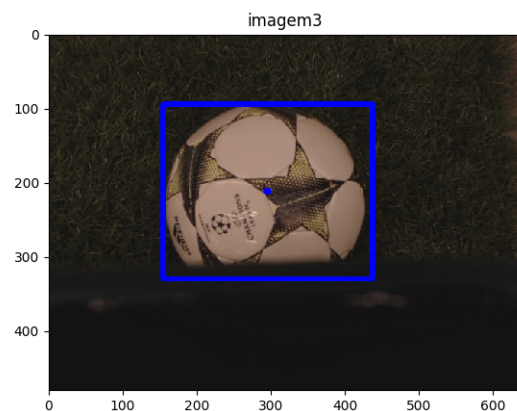


Figura 5. Detecção de uma bola (mesmo que não completamente na imagem) através do algoritmo de YOLO.




Figura 6. Detecção de um poste de trave através do algoritmo de YOLO.




Figura 7. Detecção de uma bola e dois postes da trave através do algoritmo de YOLO.